

Universidade Federal do Rio de Janeiro  
Instituto Alberto Luiz Coimbra de  
Pós-Graduação e Pesquisa de Engenharia



Programa de Engenharia de Sistemas e  
Computação

CPS769 - Introdução à Inteligência Artificial e Aprendizagem Generativa

Prof. Dr. Edmundo de Souza e Silva (PESC/COPPE/UFRJ)

Profa. Dra. Rosa M. Leão (PESC/COPPE/UFRJ)

Participação Especial: Gaspare Bruno (Diretor Inovação, ANLIX)

*Lista de Exercícios 4*

Luiz Henrique Souza Caldas

email: lhscaldas@cos.ufrj.br

12 de agosto de 2024

## Questão 1

O objetivo da lista é muito simples: entender um módulo de código e relacionar com os artigos que vimos até o momento.

Na lista 1a, você usou Python e TensorFlow para criar um modelo RNN, sendo que o código foi disponibilizado (já pronto). O programa continha:

```
1 # Define the RNN model
2
3 model = models.Sequential([
4
5     layers.LSTM(50, activation='relu', input_shape=(num_repeats, 2)),
6
7     layers.Dense(2)
8
9 ])
```

Descreva e faça um desenho para explicar qual o modelo LSTM usado. Como o modelo trata os dados temporais? Compare com a Figura 3 do artigo *Generating Text with Recurrent Neural Networks*.

### Resposta:

O modelo LSTM (Long Short-Term Memory) possui 50 neurônios em sua camada escondida, ou seja, as duas entradas serão transformadas em um vetor de 50 dimensões, que será o resultado da saída da função de ativação 'ReLU' aplicada ao produto escalar das entradas pelos respectivos pesos.

Em cada etapa temporal, a LSTM atualiza seu estado interno baseado nas entradas atuais, no estado anterior e nas saídas anteriores, preservando informações importantes ao longo da sequência. Os gates (portas) da LSTM são mecanismos que controlam o fluxo de informações dentro da célula de memória ao longo do tempo. Eles são essenciais para permitir que a LSTM decida o que lembrar e o que esquecer de uma sequência de dados. Existem três principais gates na LSTM:

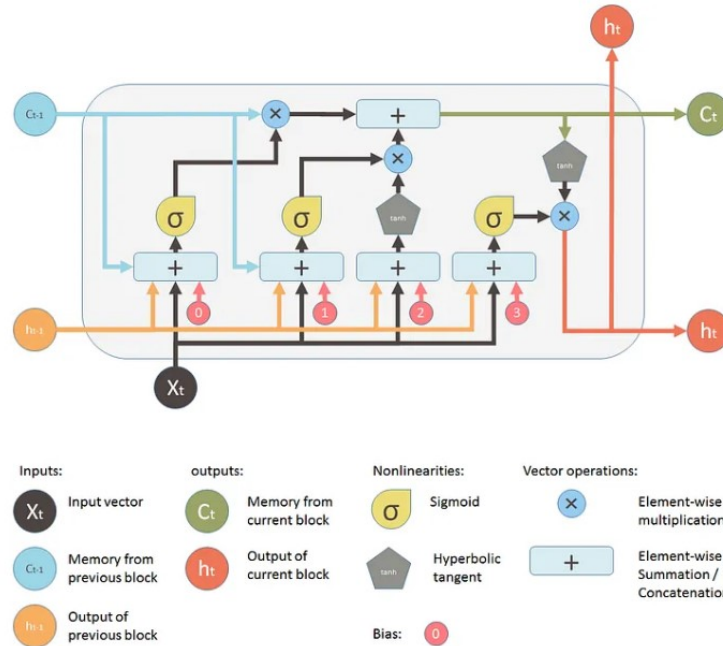
- Forget Gate (Porta de Esquecimento): Esta porta decide quanta da informação antiga deve ser esquecida. Ela recebe a entrada atual e o estado anterior e gera um valor entre 0 e 1 para cada número na célula de memória. Um valor próximo de 0 significa que a informação será esquecida, enquanto um valor próximo de 1 significa que a informação será mantida.
- Input Gate (Porta de Entrada): A porta de entrada decide quanta da nova informação que está chegando deve ser armazenada na célula de memória. Assim como a porta de esquecimento, ela gera valores entre 0 e 1 que determinam quanto da nova informação será adicionada ao estado da memória.
- Output Gate (Porta de Saída): A porta de saída decide quanta da informação da célula de memória será utilizada para gerar a saída atual da LSTM. Ela controla o que será passado para o próximo estado oculto e para a próxima camada da rede.

Essas portas trabalham juntas para garantir que informações relevantes sejam mantidas ao longo de várias etapas temporais, enquanto dados irrelevantes são descartados.

Sua estrutura pode ser observada no diagrama abaixo, com a diferença de que na figura abaixo a função de ativação é a tangente hiperbólica (tanh), enquanto que no código da lista 1a a função

de ativação era a ReLU. Os gates são representados pelos 3 conjuntos de um bloco de soma (+) e um bloco com a função de ativação sigmóide ( $\sigma$ ). Da esquerda para a direita, os gates na figura estão posicionados na seguinte ordem: esquecimento, entrada e saída.


**Figura 1:** Diagrama do modelo LSTM



Fonte: *Understanding LSTM and its diagrams.*

Comparando com a Figura 3 do artigo *Generating Text with Recurrent Neural Networks* (Hinton, 2011), a LSTM usa uma abordagem mais direta, com células que lembram informações importantes por longos períodos. Enquanto a LSTM opera principalmente através de somas ponderadas e funções de ativação simples como ReLU, a MRNN utiliza uma abordagem mais complexa onde os pesos ocultos são ajustados dinamicamente através de operações multiplicativas baseadas nos dados de entrada. Isso torna a MRNN mais flexível e capaz de capturar detalhes mais finos nos dados, especialmente em tarefas de modelagem de texto, mas também a torna mais complexa e exigente em termos de poder computacional.

**Figura 2:** Figura 3 do artigo *Generating Text with Recurrent Neural Networks*



Fonte: Hinton, 2011.

## Repositório

Este relatório encontra-se também no repositório <https://github.com/lhscaldas/cps769-ai-gen>.